

预测编码网络在语言建模中的样本效率、机制不可达性与测量纪律：一项单卡架构研究

PRISM 项目 V4-V5 技术报告

2026-09-10 | 覆盖 2026-09-07 至 09-10 的完整研究记录

关键词：非 Transformer 架构、预测编码、样本效率、因果性、消融方法学

数据与代码：G:\PRISM V4 (单卡 RTX 4080 16GB, PyTorch 2.14)

摘要

我们报告预测编码网络 (Predictive Coding Network, PCN) 在语言建模上的一项系统性单卡研究，得到四个主要发现：

- 规模-数据比规律**：误差流变体 (no_gating) 相对 Transformer 的优势随 tokens/parameter 比下降呈倒 U 形——峰值出现在 ≈ 1000 (难域 WikiText-103 上 +60.8%)，数据充裕后被反超 (-64.9%)。该规律成功预测了一个未测数据点 (WT d512 实测 +37.7%，落在预测带 [+30%, +55%])。
- 组合性质与对称不可达性**：PCN 在小样本精确复制任务上的能力 (5/5 vs 同规模 Transformer 0/30) 经 13 个变体的双向对照后，被证明**不可分解为任何单子件** (门来源、值对象、FFN、更新通路、门对比度、自信息注入六假说全部双向排除)——从标准块移植子件无法获得该能力，从 PCN 拆除子件不损失该能力。
- 局部学习规则的适用边界**：Whittington-Bogacz 式局部规则在 MLP + 迭代推断下与反向传播完全等价 (loss 0.0002 vs 0.0002)，但在 PCN 结构上存在 2.4-3.7 $\times$ 的结构性差距 (学习率与迭代推断两个混杂因素已对称排除)。
- 测量纪律**：研究过程中三次系统性测量偏差 (非因果泄露、基线超参次优、自建对照失效) 均被预设的验证程序捕获；我们将其提炼为可复用的方法学条款。

核心结论：PCN 是「低数据/参数比区间的优势架构」——该定位恰好覆盖终端个性化场景；其能力是不可移植的组合性质，必须在非 Transformer 骨架上整体产生。

1. 引言

1.1 动机

Transformer 之外的有效计算范式仍待发现：现有替代 (Mamba-2、RWKV、RetNet 等) 要么与 attention 数学等价，要么在精确回忆上存在信息论限制 (V4_PLAN 文献调研，基于 arXiv 2312.00752, 2405.21060, 2402.01032, 2504.13173 等)。本项目的长期目标是**终端私有智能**——个人设备上低功耗、可在线学习、数据不出端的架构——该场景天然处于「数据少、参数相对多」的区间，因此我们关心的核心量是**样本效率的架构依赖性**，而非绝对性能。

1.2 贡献概述

- 一条 7 数据点、经外推验证的规模-数据比规律 (§4)
- 一个 13 变体双向对照的机制分解，导出「组合性质」结论 (§5)
- 局部学习规则从等价到失效的完整边界刻画 (§6)
- 三次测量危机的完整记录与提炼出的方法学 (§3)

2. 架构与实现修正

2.1 PCN 架构

每层包含：自底向上提取 $u = W_{bu}(LN(x))$ ；自顶向下预测 $p = W_{td}(h_{above})$ ；预测误差 $e = clamp(u - p, \pm 10)$ ；**误差驱动的跨位置门控聚合**——压缩特征交互 $[e_i \odot e_j, e_i + e_j]$ 经 sigmoid 独立门（非 softmax 竞争）、因果掩码、Top-K 稀疏化后加权 $W_{lat}(e)$ ；状态更新 $h = GELU(W_{up}(LN(e + lat))) + W_{res}(x)$ (W_{res} 恒等初始化)。

消融变体（贯穿全文）：

- **no_gating**：门控聚合换成果因 attention（误差流保留）——本文最强的「误差流」载体
- **two_pass**：真 top-down（pass 2 用更深一层状态做预测来源）
- 反馈消融、门控 softmax 化、门来源/值对象开关 (§5)

2.2 三轮实现修正（首次报告，附教训）

轮次	缺陷	症状	修复
R1	W_{res} 随机初始化（谱范数 ≈ 0.6 ） $\rightarrow$ 12 层梯度衰减 $316\times$ ；门控双重小尺度压缩 $\rightarrow g=0.5$ 死锁；evaluate 未透传消融参数	PPL 卡 406 五千步不动	恒等初始化 + 门控 LayerNorm/Xavier + 参数透传
R2	非因果泄露 （attention 未传 attn_mask、门控无掩码）——两个架构都能「看未来」	22M 模型 held-out WikiText top-1 准确率 99.6%	双侧因果化 (§3.1)
R3	基线超参次优 ($lr=3e-4$ 对 Transformer 严重次优，其最优为 $1e-3$)	假性 +56.8% 优势	对称 lr 扫描 (§3.2)

全部双向时代数据（75 项）作废归档；本文所有数字均为因果修正后。

3. 测量方法学（三次危机的提炼）

3.1 因果性是公理，不是配置项

任何「预测下一 token」的跨位置交互必须显式因果化。**作弊探测器**：训练后模型在 held-out 真实语料上 top-1 准确率 $> 50\%$ 或 PPL 异常低 (< 5)，几乎必然非因果——本研究的泄露正是由「PPL 2.24 好到不可能」暴露，而非代码审查发现。

3.2 对照超参必须对称调优

统计稳定性（多 seed、小方差）不能补偿系统性偏差：我们的假性优势有 5-seed、std 0.012 的完美统计形态，仍然源于基线 lr 次优。任何架构对比必须双方各自完成同规模超参扫描后取各自最优。**架构最优超参本身是结果**：本研究的 Transformer 最优 lr ($1e-3$) 与误差流变体 ($5e-4$) 相差 2-3 倍，且互换代价巨

大 (-83% 至发散)。

3.3 自建对照结构必须先用已知结论校准对照格

为分解实验在外部重写的「简化结构」= 未声明的多变量改动。本研究三次自建结构全部对照失效（含已知格复现失败）。正确做法：在原实现上加开关，并先跑对照格校准。

3.4 同预算协议

一切对比固定 batch × seq × steps 的 token 总量与等效 batch；单变量三臂消融（full / 去 X / 换 X）。

4. 主结果：规模-数据比规律

4.1 协议

TinyStories / WikiText-103（GPT-2 tokenizer, 117.9M tokens 磁盘缓存），seq 256, 41M tokens 固定预算（5000 步 × 等效 batch 32），双方各自最优 lr 与 clip，多 seed。模型 12 层，d ∈ {256, 384, 512}（21-63M 参数）。

4.2 规律曲线（7 数据点，权威全 seed 聚合）

tokens/param	TinyStories（简单域）	WikiText-103（难域）
~7500（164M tokens）	—	-64.9%（TF 全胜）
~1900	-8.8%（TF 15.18±0.80 / NG 16.50±0.07, n=5）	+20.7%（TF 221.97±17.90 / NG 175.96±0.53, n=5）
~1025	+43.3%（TF 20.04±1.16 / NG 11.37±0.58, n=5）	+60.8%（TF 390.08±131.76 / NG 152.92±34.04, n=3）
~650	+35.5%（n=3）	+37.7%（n=2）

（正值 = no_gating 优于调优 Transformer；完整数字与显式 run 清单见 analysis_v2/scale_data_ratio_curve_AUTH.json）

附带发现（稳定性）：NG 的 seed 标准差在两个低数据点上比 TF 小 1-2 个数量级（WT d256: 0.53 vs 17.90；WT d512: 2.39 vs 65.66）——**误差流不仅更准，训练还显著更稳定**，这对端侧部署（不可挑选 seed）是独立于 PPL 的实际优势。

形状：倒 U 形。优势峰值在 tokens/param ≈ 1000；**域难度是第二主轴**（同比 1025：难域 +60.8% vs 简单域 +43.3%），且难域峰值更高、衰减更快（650 时 37.7 vs 35.5）。**置信度笔记：**峰值点（WT d384）n=3 且 TF 侧方差大（±131.76）——60.8% 的点估计有较宽区间，但 NG 均值低于 TF 全部 3 个 seed 的最小值，方向稳健。

外推验证：WT d512 数据点在曲线其余部分确定后预测（预测带 [+30%, +55%]），实测 +37.7% 落在带内——规律的第一次成功预测。

充分训练翻转：WT d256 @164M tokens（20K 步）下 Transformer 53.1 vs no_gating 87.5——数据充裕后 TF 渐近优势接管。误差流的优势严格属于低数据/参数比区间。

4.4 第三架构对照（09-10 补充）

以可学习因果衰减注意力（softmax(QK⊞+λ(t-i))），RetNet/GLA 线性注意力家族的最小代理；Mamba/RWKV 在 Windows 不可编译，纯 torch 复刻的数值风险大于代理价值）作为第三族：

域	decay 最优	Transformer	no_gating
TinyStories	15.95	15.18±0.80	16.50±0.07
WikiText-103 (低数据区)	213.86	221.97±17.90	175.96±0.53

decay 略优于 TF (WT 上 +3.7%) 但**远不具备误差流的低数据区优势** (NG 对 decay 领先 17.8%) —— 误差流的 +20.7% **不是「替换 softmax」或「添加衰减先验」类单子件改动可以获得的**，与 §5 的组合性质结论形成跨实验呼应 (decay 为单 seed/单 lr 点，方向性结论)。

4.5 定位含义

终端个性化场景 (用户数据有限 × 相对大参数) 恰好落在峰值区——该规律为「什么区间用什么架构」提供了可操作的决策依据。诚实边界：43-61% 是改进幅度而非数量级跃迁；规律在 <650 与 >1B 参数两个方向均未测。

5. 机制分析：组合性质与对称不可达性

5.1 现象

小样本精确复制任务 (H 个随机 token + 分隔符 + 复制, 1000 步预算, 12L-64d)：因果 PCN **5/5 seed 学会** (copy loss 0.17-0.32)，同规模因果 Transformer **0/30** (恒 unigram 3.43；因果版三长度 ×5 seed 0/15 + lr 调优复检 0/15)。

5.2 十三变体双向对照 (3-seed each)

已排除的必要条件假说 (加法线失败 + 反向线存活 = 双向排除)：

假说	标准块+子件	PCN-子件
门来源 (feat 交互 vs q-k 相似度)	—	qk 门在 PCN 内 0.047-0.092 □
值对象 (误差 e vs 输入 h)	—	wlat_h 0.022 □ (比 e 更好)
误差残差性 (e=u-p)	—	e=u (no_feedback) 0.277 □
FFN 干扰	去 FFN 3.437 □	+FFN 0.074 □
更新通路形态	S2/S3 3.435 □	原生 □
门对比度 (头平均)	单头门 3.435 □	原生 □
自信息直注增量	S5 3.435 □	—
独立 sigmoid (vs softmax 竞争)	—	softmax 化 1.109 (3/5 不稳定) □□

softmax 竞争化是唯一使 PCN 退化的单改动 (不稳定而非完全失败) ——独立门是该列表中**唯一存留的单子件必要条件**，但仅有它不够 (tf_sigmoid 有独立门仍失败)。

5.3 结论：组合性质

复制能力的必要条件是 **PCN 骨架多个子件的组合**——提取-误差-融合-恒等残差的耦合结构，不可分解为单一组件。

5.4 对称不可达性

- 性能层 (V1-V3, 20+ 实验)：从 Transformer 修补出发 → 退回 Transformer
- 机制层 (本研究)：从标准块移植子件 (五种) → 救不回复制能力；从 PCN 拆除已测子件 → 能力保持

□ **该能力必须在非 Transformer 骨架的基线上整体产生，不可通过组件移植获得。** 这为「换基线而非打补丁」的架构研究策略提供了机制层证据。

5.5 行为签名（补充）

跨模型 CKA：纯 PCN (two_pass) 0.112 / 混合版 0.469——表示结构差异显著。误差范数与 token 惊讶度的相关四次测量 ≈ 0 (0.10/0.05/0.015/-0.06)：「误差编码惊讶」的经典预测编码假说在本设置下未获支持。

6. 负结果：局部学习规则的适用边界

级别	设置	结果
0	两层 MLP + K 步迭代推断	完全等价 (0.0002 vs 0.0002; K=1 输出层梯度 cos = 0.9995)
1	PCN 的 W_td (玩具任务)	零敏感度 (冻结/局部/全 BP 的 loss 全同——任务不依赖反馈)
2	PCN 主路径 (LM)	2.4-3.7× 差距 (m1 = 39.8-49.6 vs 基线 13.6-16.6)

级别 2 的两个混杂因素已对称排除：局部 lr 四点扫描（全平台 2.4-2.6×）； $K \in \{2,3\}$ 迭代推断矩阵（数值稳定但性能更差，且 K-pass 纯 BP 对照 13.60 证明推断本身无代价）。

结论：W&B 局部规则与反向传播的等价性**不跨越结构复杂度边界**——在「MLP+推断收敛」与「PCN 结构」之间存在系统性的失效跃迁。「以局部规则实现终端在线学习」的路径需要非 W&B 形式，或等待新的理论。

附带发现：grad_clip 0.5 对 no_gating 更优 (16.56→14.13)；所谓 K-pass 增益 (13.84) 实为 clip 混杂（差 2% 在噪声内）。

7. 讨论与局限

7.1 对终端智能愿景的含义

倒 U 规律的峰值区与终端个性化场景重合，为「预训练用 Transformer、终端个性化区用误差流架构」的混合策略提供了依据。但 43-61% 的幅度不足以单独支撑终端愿景——稀疏化（激活效率）、在线学习（本报告的负结果表明其理论通路尚未打通）与系统工程的叠加仍是必需。

7.2 局限（诚实清单）

- 1. 规模上限 63M 参数 / 单卡——规律在 >1B 与 <650 两端未测
- 2. 第三架构以衰减注意力为代理（RetNet/GLA 家族精神），完整 Mamba/RWKV 未测；代理与 TF 重合暗示衰减核家族可能同样不具备该优势，但需正式实现确认
- 3. 复制任务是合成任务；「1000 步内学不会」≠「永远学不会」——结论限于小样本预算
- 4. 倒 U 的机理（为何低数据区占优）只有现象学刻画，无理论模型
- 5. 单实现、单 tokenizer 族；软件工程成熟度低（门控吞吐仅为优化 attention 的 ~16%，torch.compile 负优化）

7.3 方法学立场

本研究的三次测量危机全部被**预设的验证程序**（而非运气）捕获。我们主张：架构比较论文应报告其验证程序（因果探测器、超参对称性、对照校准）与结果本身同等重要的地位——尤其在单点「惊人优势」出现时，**先怀疑测量，再相信架构**。

附录 A：关键数字索引

数据	文件
规律曲线 7 点	results/analysis_v2/scale_data_ratio_curve.json
因果 5-seed（两域）	results/analysis_v2/{ts,wt}_causal_seed_validation.json
公平判定 + d384/d512	results/analysis_v2/fairness_final.json, d384_confirm.json
机制 13 变体	results/mechanism/{copy_mechanism_s*.json, gate_source_v2.json, block_ablation.json}
局部规则三级别	results/mechanism/{local_rule_test 系, local_rule_level*_*.json}
行为签名	results/analysis_v2/signatures_causal_*.json
双向时代作废归档	results/_invalid_bidirectional/（README 含报警现场）

附录 B：实验统计

约 130 个训练 run（含作废 75 项）；GPU 总时长 $\approx$ 40 小时；全部实验可由 run_*.sh 幂等复现。

PRISM V4-V5 · 2026-09-07 至 09-10 · 单卡架构研究完整记录