

预测编码网络在语言建模中的样本效率、机制不可达性与测量纪律：一项单卡架构研究

PRISM 项目 V4-V5 技术报告

2026-09-11 v2.1 | 覆盖 2026-09-07 至 09-11 的完整研究记录

关键词：非 Transformer 架构、预测编码、样本效率、因果性、消融方法学

代码与数据已开源：<https://github.com/Asaluther/PRISM-V4>

单卡 RTX 4080 16GB, PyTorch 2.14, ~140 training runs

摘要

我们报告预测编码网络（Predictive Coding Network, PCN）在语言建模上的一项系统性单卡研究，得到四个主要发现：

- 规模-数据比规律**：误差流变体（no_gating）相对 Transformer 的优势随 tokens/parameter 比下降呈倒 U 形——峰值出现在 ≈ 1000 （难域 WikiText-103 上 +60.8%），数据充裕后被反超（-64.9%）。该规律成功预测了一个未测数据点（WT d512 实测 +37.7%，落在预测带 [+30%, +55%]）。
- 组合性质与对称不可达性**：PCN 在小样本精确复制任务上的能力（5/5 vs 同规模 Transformer 0/30）经 13 个变体的双向对照后，被证明**不可分解为任何单子件**（门来源、值对象、FFN、更新通路、门对比度、自信息注入六假说全部双向排除）——从标准块移植子件无法获得该能力，从 PCN 拆除子件不损失该能力。
- 局部学习规则的适用边界**：Whittington-Bogacz 式局部规则在 MLP + 迭代推断下与反向传播完全等价（loss 0.0002 vs 0.0002），但在 PCN 结构上存在 2.4-3.7 $\times$ 的结构性差距（学习率与迭代推断两个混杂因素已对称排除）。
- 测量纪律**：研究过程中三次系统性测量偏差（非因果泄露、基线超参次优、自建对照失效）均被预设的验证程序捕获；我们将其提炼为可复用的方法学条款。

核心结论：PCN 是「低数据/参数比区间的优势架构」——该定位恰好覆盖终端个性化场景；其能力是不可移植的组合性质，必须在非 Transformer 骨架上整体产生。

1. 引言

1.1 动机

Transformer 之外的有效计算范式仍待发现：现有替代（Mamba-2、RWKV、RetNet 等）要么与 attention 数学等价，要么在精确回忆上存在信息论限制（V4_PLAN 文献调研，基于 arXiv 2312.00752, 2405.21060, 2402.01032, 2504.13173 等）。本项目的长期目标是**终端私有智能**——个人设备上低功耗、可在线学习、数据不出端的架构——该场景天然处于「数据少、参数相对多」的区间，因此我们关心的核心量是**样本效率的架构依赖性**，而非绝对性能。

1.2 贡献概述

- 一条 7 数据点、经外推验证的规模-数据比规律 (§4)
- 一个 13 变体双向对照的机制分解，导出「组合性质」结论 (§5)
- 局部学习规则从等价到失效的完整边界刻画 (§6)
- 三次测量危机的完整记录与提炼出的方法学 (§3)

2. 架构与实现修正

2.1 PCN 架构

每层包含：自底向上提取 $u = W_{bu}(LN(x))$ ；自顶向下预测 $p = W_{td}(h_{above})$ ；预测误差 $e = clamp(u - p, \pm 10)$ ；**误差驱动的跨位置门控聚合**——压缩特征交互 $[e_i \odot e_j, e_i + e_j]$ 经 sigmoid 独立门（非 softmax 竞争）、因果掩码、Top-K 稀疏化后加权 $W_{lat}(e)$ ；状态更新 $h = GELU(W_{up}(LN(e + lat))) + W_{res}(x)$ (W_{res} 恒等初始化)。

消融变体（贯穿全文）：

- **no_gating**：门控聚合换成因果 attention（误差流保留）——本文最强的「误差流」载体
- **two_pass**：真 top-down（pass 2 用更深一层状态做预测来源）
- 反馈消融、门控 softmax 化、门来源/值对象开关 (§5)

2.2 三轮实现修正（首次报告，附教训）

轮次	缺陷	症状	修复
R1	W_{res} 随机初始化（谱范数 ≈ 0.6 ） $\rightarrow$ 12 层梯度衰减 $316\times$ ；门控双重小尺度压缩 $\rightarrow g=0.5$ 死锁；evaluate 未透传消融参数	PPL 卡 406 五千步不动	恒等初始化 + 门控 LayerNorm/Xavier + 参数透传
R2	非因果泄露 （attention 未传 attn_mask、门控无掩码）——两个架构都能「看未来」	22M 模型 held-out WikiText top-1 准确率 99.6%	双侧因果化 (§3.1)
R3	基线超参次优 ($lr=3e-4$ 对 Transformer 严重次优，其最优为 $1e-3$)	假性 +56.8% 优势	对称 lr 扫描 (§3.2)

全部双向时代数据（75 项）作废归档；本文所有数字均为因果修正后。

3. 测量方法学（三次危机的提炼）

3.1 因果性是公理，不是配置项

任何「预测下一 token」的跨位置交互必须显式因果化。**作弊探测器**：训练后模型在 held-out 真实语料上 top-1 准确率 $> 50\%$ 或 PPL 异常低 (< 5)，几乎必然非因果——本研究的泄露正是由「PPL 2.24 好到不可能」暴露，而非代码审查发现。

3.2 对照超参必须对称调优

统计稳定性（多 seed、小方差）不能补偿系统性偏差：我们的假性优势有 5-seed、std 0.012 的完美统计形态，仍然源于基线 lr 次优。任何架构对比必须双方各自完成同规模超参扫描后取各自最优。**架构最优超参本身是结果**：本研究的 Transformer 最优 lr (1e-3) 与误差流变体 (5e-4) 相差 2-3 倍，且互换代价巨大 (-83% 至发散)。

3.3 自建对照结构必须先用已知结论校准对照格

为分解实验在外部重写的「简化结构」= 未声明的多变量改动。本研究三次自建结构全部对照失效（含已知格复现失败）。正确做法：在原实现上加开关，并先跑对照格校准。

3.4 同预算协议

一切对比固定 batch × seq × steps 的 token 总量与等效 batch；单变量三臂消融（full / 去 X / 换 X）。

4. 主结果：规模-数据比规律

4.1 协议

TinyStories / WikiText-103 (GPT-2 tokenizer, 117.9M tokens 磁盘缓存)，seq 256, 41M tokens 固定预算 (5000 步 × 等效 batch 32)，双方各自最优 lr 与 clip，多 seed。模型 12 层，d ∈ {256, 384, 512} (21-63M 参数)。

4.2 规律曲线 (v2: 二维不对称, 11 数据点, bootstrap 95% CI)

减数据轴 (固定 d256, 数据量递减) ——优势单调上升, 无左端回落：

tokens	TF [95% CI]	NG [95% CI]	NG 优势	稳健性
2.5M	402.67	63.95	+84.1%	全胜
5M	268.63	42.93	+84.0%	全胜
10M	128.82	28.27	+78.1%	全胜
20M	32.88	19.92	+39.4%	全胜
41M	15.18 [14.66,15.86]	16.50 [16.45,16.55]	-8.8%	负

加参数轴 (固定 41M tokens) ——倒 U：

tokens/param	TS	WT	稳健性
~7500	—	-64.9%	负
~1900	-8.8%	+20.7% (TF [210,238] / NG [175.6,176.4])	全胜
~1025	+43.3%	+59.2% (n=5; TF [290,447] / NG [128,168])	全胜
~650	+35.5%	+48.5% (n=5; 全胜)	全胜

逐点 CI 与 run 清单：analysis_v2/scale_curve_with_ci.json。【全胜】= NG 最差 seed 优于 TF 最好 seed——所有正优势点均达此标准（强于 CI 不重叠）。

结论 (范围限定表述, 响应审稿 W1)：在本研究参数范围 (21-63M)、token 预算 (≤164M) 与两个域内：误差流优势随数据稀缺单调增大 (至 +84%)；随参数加大先增后减 (峰值 ≈1025 tokens/param)。「减数据比加参数更能放大优势」直接指导终端个性化部署（冻结中等模型 + 少量用户数据）。>1B 参数与 >164M tokens 未测。

附带发现（稳定性）：NG 的 seed 标准差在两个低数据点上比 TF 小 1-2 个数量级（WT d256: 0.53 vs 17.90；WT d512: 2.39 vs 65.66）——**误差流不仅更准，训练还显著更稳定**，这对端侧部署（不可挑选 seed）是独立于 PPL 的实际优势。

域难度主轴：同比 1025 tokens/param，难域（WT）优势高于简单域（TS）约 17 个点；v1 的「倒 U」表述在数据量轴上不成立（见上表：单调），仅在参数轴成立——v2 已按二维不对称规律改写。

外推验证：WT d512 数据点在曲线其余部分确定后预测（预测带 [+30%, +55%]），实测 +37.7% 落在带内——规律的第一次成功预测。

充分训练翻转：WT d256 @164M tokens（20K 步）下 Transformer 53.1 vs no_gating 87.5——数据充裕后 TF 渐近优势接管。误差流的优势严格属于低数据/参数比区间。

4.3R 超参敏感性对照（v2，响应审稿 W2/W4）

warmup	TF (lr 1e-3)	NG (lr 5e-4)
100	14.98	14.85
500（基线）	15.14	14.13
1500	13.55	14.01

发现：warmup 对 TF 敏感（500→1500 改善 10.5%）、对 NG 不敏感（±1%）。两边各自最优时收敛区（TS d256）差距为 TF 领先 3.4%（此前单一 warmup 下的 8.7% 含超参不对称成分）。**关键定量论证：**warmup 敏感性的量级（~10%）远小于低数据区优势（+59%~+84%），规律的主结论不受此混杂威胁。

4.4 第三架构对照（09-10 补充）

以**可学习因果衰减注意力**（softmax(QK[⊥]+λ(t-i))），RetNet/GLA 线性注意力家族的最小代理；Mamba/RWKV 在 Windows 不可编译，纯 torch 复刻的数值风险大于代理价值）作为第三族：

域	decay 最优	Transformer	no_gating
TinyStories	15.95	15.18±0.80	16.50±0.07
WikiText-103（低数据区）	213.86	221.97±17.90	175.96±0.53

decay 略优于 TF（WT 上 +3.7%）但**远不具备误差流的低数据区优势**（NG 对 decay 领先 17.8%）——误差流的 +20.7% **不是「替换 softmax」或「添加衰减先验」类单子件改动可以获得的**，与 §5 的组合性质结论形成跨实验呼应（decay 为单 seed/单 lr 点，方向性结论）。

4.5 定位含义

终端个性化场景（用户数据有限 × 相对大参数）恰好落在峰值区——该规律为「什么区间用什么架构」提供了可操作的决策依据。诚实边界：43-61% 是改进幅度而非数量级跃迁；规律在 <650 与 >1B 参数两个方向均未测。

5. 机制分析：组合性质与对称不可达性

5.1 现象

小样本精确复制任务（H 个随机 token + 分隔符 + 复制，1000 步预算，12L-64d）：**因果 PCN 5/5 seed 学会**（copy loss 0.17-0.32），同规模因果 Transformer **0/30**（恒 unigram 3.43；因果版三长度 ×5 seed 0/15 + lr 调优复检 0/15）。

5.2 十三变体双向对照 (3-seed each)

已排除的必要条件假说（加法线失败 + 反向线存活 = 双向排除）：

假说	标准块+子件	PCN-子件
门来源 (feat 交互 vs q-k 相似度)	—	qk 门在 PCN 内 0.047-0.092 □
值对象 (误差 e vs 输入 h)	—	wlat_h 0.022 □ (比 e 更好)
误差残差性 (e=u-p)	—	e=u (no_feedback) 0.277 □
FFN 干扰	去 FFN 3.437 □	+FFN 0.074 □
更新通路形态	S2/S3 3.435 □	原生 □
门对比度 (头平均)	单头门 3.435 □	原生 □
自信息直注增量	S5 3.435 □	—
独立 sigmoid (vs softmax 竞争)	—	softmax 化 1.109 (3/5 不稳定) □□

softmax 竞争化是唯一使 PCN 退化的单改动（不稳定而非完全失败）——独立门是该列表中**唯一存留的单子件必要条件**，但仅有它不够（tf_sigmoid 有独立门仍失败）。

5.2R 全因子补格 (v2, 响应审稿 W3: 交互效应检验)

2×2×2 全因子矩阵（门来源 × 值对象 × FFN，各 3 seed，factorial_fill.json）：

	e 值	h 值
feat 门 - FFN	0.21 □	0.022 □
feat 门 + FFN	0.31 □	0.27 □
qk 门 - FFN	0.09 □	0.047 □
qk 门 + FFN	0.14 □	0.074 □

八格全部成功——PCN 骨架内不存在能破坏复制能力的子件组合；主效应与交互效应均为「无害」。结合标准块侧五连败 (§5.2)，组合性质结论从「检验过的变体集」升级为**完整因子空间内确认**。

5.3 结论：组合性质

复制能力的必要条件是 **PCN 骨架多个子件的组合**——提取-误差-融合-恒等残差的耦合结构，不可分解为单一组件。

5.4 对称不可达性

- 性能层 (V1-V3, 20+ 实验)：从 Transformer 修补出发 → 退回 Transformer
- 机制层 (本研究)：从标准块移植子件 (五种) → 救不回复制能力；从 PCN 拆除已测子件 → 能力保持 □ **在我们检验的变体集、训练预算 (1000 步) 与移植策略下，该能力未能通过子件移植复现，也未能通过拆除子件消除。** 我们无法断言此结论在更大规模、更多干预方式（如渐进式移植、初始化匹配、辅助损失训练等）下仍然成立——但这组双向证据支持「换基线而非打补丁」的架构研究策略。

5.5 行为签名 (补充)

跨模型 CKA：纯 PCN (two_pass) 0.112 / 混合版 0.469——表示结构差异显著。误差范数与 token 惊讶度的相关四次测量 ≈ 0 (0.10/0.05/0.015/-0.06)：「误差编码惊讶」的经典预测编码假说在本设置下**未获支持**。

6. 负结果：局部学习规则的适用边界

级别	设置	结果
0	两层 MLP + K 步迭代推断	完全等价 (0.0002 vs 0.0002; K=1 输出层梯度 cos = 0.9995)
1	PCN 的 W_td (玩具任务)	零敏感度 (冻结/局部/全 BP 的 loss 全同——任务不依赖反馈)
2	PCN 主路径 (LM)	2.4-3.7× 差距 (m1 = 39.8-49.6 vs 基线 13.6-16.6)

级别 2 的两个混杂因素已对称排除：局部 lr 四点扫描（全平台 2.4-2.6×）； $K \in \{2,3\}$ 迭代推断矩阵（数值稳定但性能更差，且 K-pass 纯 BP 对照 13.60 证明推断本身无代价）。

结论（限定范围表述）：在本研究的 W&B 实现变体、更新方案 ($K \in \{1,2,3\}$) 与优化设置下，等价性在「MLP+推断收敛」与「PCN 结构」之间存在 2.4-3.7× 的性能差距。我们**不能**由此推广到所有生物合理的局部学习规则——其他变体（如松弛权重对称性、不同阻尼、更大 K 值、反馈对齐等）可能在 PCN 上表现不同。「以局部规则实现终端在线学习」的路径需要探索非 W&B 形式或等待新理论。

附带发现：grad_clip 0.5 对 no_gating 更优 (16.56→14.13)；所谓 K-pass 增益 (13.84) 实为 clip 混杂（差 2% 在噪声内）。

7. 讨论与局限

7.1 对终端智能愿景的含义

倒 U 规律的峰值区与终端个性化场景重合，为「预训练用 Transformer、终端个性化区用误差流架构」的混合策略提供了依据。但 43-61% 的幅度不足以单独支撑终端愿景——稀疏化（激活效率）、在线学习（本报告的负结果表明其理论通路尚未打通）与系统工程的叠加仍是必需。

7.2 局限（诚实清单）

- 1. 规模上限 63M 参数 / 单卡——规律在 >1B 与 <650 两端未测
- 2. 第三架构以衰减注意力为代理（RetNet/GLA 家族精神），完整 Mamba/RWKV 未测；代理与 TF 重合暗示衰减核家族可能同样不具备该优势，但需正式实现确认
- 3. 复制任务是合成任务；「1000 步内学不会」≠「永远学不会」——结论限于小样本预算
- 4. 倒 U 的机理（为何低数据区占优）只有现象学刻画，无理论模型
- 5. 单实现、单 tokenizer 族；v2 已通过门控数学等价重构（bmm+偏置形式）将训练吞吐从 TF 的 16% 提升至 96%、推理 batch≥16 反超 +14%、int8 量化无损——效率限制基本解除，但 batch 1 终端推理（60% TF）仍有 kernel 级优化空间（详见 efficiency/EFFICIENCY_REPORT.md）

7.2R 规模扩展计划（响应审稿 W1）

阶段	目标	预计时间
短期（8 周内）	一个 200-300M 参数点在 WikiText-103 上的验证	获取多卡资源后启动
中期（6 个月）	200M + 500M 两档完整 tokens/param 曲线	视资源情况
长期	>1B 参数验证	需集群级算力

操作建议的条件限定：终端个性化部署建议仅在 $\text{tokens/param} \in [\sim 650, \sim 1100]$ 且参数 $\leq 1e8$ 的区间内直接适用；超出此范围需先验证。

7.3 方法学立场

本研究的三次测量危机全部被**预设的验证程序**（而非运气）捕获。我们主张：架构比较论文应报告其验证程序（因果探测器、超参对称性、对照校准）与结果本身同等重要的地位——尤其在单点「惊人优势」出现时，**先怀疑测量，再相信架构**。

附录 A：关键数字索引

开源仓库： <https://github.com/Asaluther/PRISM-V4> — 全部代码、run 脚本、结果 JSON 可复现

数据	文件
规律曲线 7 点	results/analysis_v2/scale_data_ratio_curve.json
因果 5-seed（两域）	results/analysis_v2/{ts,wt}_causal_seed_validation.json
公平判定 + d384/d512	results/analysis_v2/fairness_final.json, d384_confirm.json
机制 13 变体	results/mechanism/{copy_mechanism_s*.json, gate_source_v2.json, block_ablation.json}
局部规则三级别	results/mechanism/{local_rule_test 系, local_rule_level*_*.json}
行为签名	results/analysis_v2/signatures_causal_*.json
双向时代作废归档	results/_invalid_bidirectional/（README 含报警现场）

附录 B：实验统计

约 130 个训练 run（含作废 75 项）；GPU 总时长 ≈ 40 小时；全部实验可由 `run_*.sh` 幂等复现。

PRISM V4-V5 · 2026-09-07 至 09-10 · 单卡架构研究完整记录

附录 C：术语表（响应审稿 W5）

缩写	全称/定义
PCN	预测编码网络（Predictive Coding Network），本研究的非 Transformer 骨架
NG / no_gating	PCN 的误差流变体：门控聚合替换为因果 attention，误差流保留——最强配置
TF	Transformer 对照基线（Pre-LN + SDPA 因果注意力）
误差流	$e = u - p$ （自底向上提取减自顶向下预测），逐层计算的残差信号
门控通路	PCN 的跨位置聚合机制：压缩特征交互 $\rightarrow$ sigmoid 独立门 $\rightarrow$ Top-K $\rightarrow$ 加权 W_{lat} 值
对称不可达性	从标准块移植子件无法获得、从 PCN 拆除子件不损失某能力的双向实验性质
tokens/param	训练 token 总量 $\div$ 参数量（数据-参数比）

缩写	全称/定义
全胜	NG 的最差 seed 优于 TF 的最好 seed (强于 95% CI 不重叠的稳健性声明)
W&B 局部规则	Whittington–Bogacz 式预测编码局部学习规则 (无需全局反向传播)
K-pass	迭代推断: K 遍前向中逐层松弛误差 (W&B 等价性的推断条件)

附录 D: 审稿意见回应索引 (v2)

审稿弱点	响应	所在节
W1 规模/外推	措辞限定 + 二维规律改写 + 峰值点 n=5	§4.2
W2 基线/超参对称	warmup 敏感对照 + decay n=3 + 定量论证	§4.3R/§4.4
W3 因子设计	2×2×2 全因子 8 格补齐 (全部成功)	§5.2R
W4 统计细节	bootstrap CI + 「全胜」稳健性声明	§4.2
W5 可复现性	术语表 (本附录 C) ; 开源仓库计划: GitHub + smoke test + 相对路径 (下版)	附录 C/D
效率局限#5	bmm 重构 6.12× (达 TF 96%) + 推理 batch32 反超 +14%	efficiency/EFFICIENCY_REPORT.md