

预测编码网络在语言建模中的样本效率、机制不可达性与测量纪律：一项单卡架构研究

PRISM 项目 V4-V5 技术报告

2026-09-16 v4 | 覆盖 2026-09-07 至 09-16 的完整研究记录 (v4 新增: V7 终端形态——稀疏激活与冷启动兼容、CPU 端侧部署、安全框架、第五次测量偏差修正)

关键词: 非 Transformer 架构、预测编码、样本效率、因果性、消融方法学

代码与数据已开源: <https://github.com/Asaluther/PRISM-V4>

单卡 RTX 4080 16GB, PyTorch 2.14, ≈ 170 有效训练 run (含 V6/V7 系列) (另含 75 项作废归档; 口径详见附录 B)

摘要

我们报告预测编码网络 (Predictive Coding Network, PCN) 在语言建模上的一项系统性单卡研究, 得到四个主要发现:

- 规模-数据比规律:** 误差流变体 (no_gating) 相对 Transformer 的优势随 tokens/parameter 比下降呈倒 U 形——峰值出现在 ≈ 1000 (难域 WikiText-103 上 +60.8%), 数据充裕后被反超 (-64.9%)。该规律成功预测了一个未测数据点 (WT d512 实测 +37.7%, 落在预测带 [+30%, +55%])。
- 组合性质与对称不可达性:** PCN 在小样本精确复制任务上的能力 (5/5 vs 同规模 Transformer 0/30) 经 13 个变量的双向对照后, 被证明不可分解为任何单子件 (门来源、值对象、FFN、更新通路、门对比度、自信息注入六假说全部双向排除)——从标准块移植子件无法获得该能力, 从 PCN 拆除子件不损失该能力。微调时的权重变化幅度约束 ($\Delta W \approx TF/2$) 呈现同一模式 (四个单子件假说双向排除; 对公平基线稳健 1.91 $\times$), 构成第二个涌现性质。
- 局部学习规则的适用边界:** Whittington-Bogacz 式局部规则在 MLP + 迭代推断下与反向传播完全等价 (loss 0.0002 vs 0.0002), 但在 PCN 结构上存在 2.4-3.7 $\times$ 的结构性差距 (学习率与迭代推断两个混杂因素已对称排除)。
- 测量纪律:** 研究过程中四次系统性测量偏差 (非因果泄露、基线超参次优——含 V6 系列的一次复发并勘误、自建对照失效、合成基准频率捷径) 均被预设的验证程序捕获; 我们将其提炼为可复用的方法学条款。
- 终端适应的真实边界 (v2.2 新增):** 误差流的适应优势属于跨域/冷启动——单发少量数据微调 +58.5% vs 公平 TF +5.4%, 真实流式 (一次性逐批) +24.0% vs TF -80.9%; 但域内个性化无适应空间 (24 格校准网格双架构全负), 且匹配适应水平下 PCN 的遗忘更多而非更少 (ΔW 小 $\neq$ 功能稳定——权重约束重定性为「参数经济性/高函数敏感度」)。部署准则: 冷启动用 PCN 边用边学, 域内已收敛则冻结。
- 稀疏激活与冷启动完全兼容 (v4 新增):** Top-K 25% 激活稀疏化使 PPL 改善 14.4%, 且经四臂对照验证跨域冷启动能力完全保留 (+57.9% vs 稠密 +53.2%)。CPU 端侧验证: 推理 8.6K tok/s、冷启动适应 22.7 秒、模型 80MB、全本地无网络调用。

核心结论：PCN 是「低数据/参数比区间的优势架构」——其可兑现场景是**跨域冷启动适应**（换域/新用户冷启动），而非域内风格微调；其能力是不可移植的组合性质，必须在非 Transformer 骨架上整体产生。

1. 引言

1.1 动机

Transformer 之外的有效计算范式仍待发现：现有替代（Mamba-2、RWKV、RetNet 等）要么与 attention 数学等价，要么在精确回忆上存在信息论限制（V4_PLAN 文献调研，基于 arXiv 2312.00752, 2405.21060, 2402.01032, 2504.13173 等）。本项目的长期目标是**终端私有智能**——个人设备上低功耗、可在线学习、数据不出端的架构——该场景天然处于「数据少、参数相对多」的区间，因此我们关心的核心量是**样本效率的架构依赖性**，而非绝对性能。

1.2 贡献概述

- 一条 7 数据点、经外推验证的规模-数据比规律 (§4)
- 一个 13 变体双向对照的机制分解，导出「组合性质」结论；及其在权重约束上的再现（第二涌现性质，§5/§7.1）
- 局部学习规则从等价到失效的完整边界刻画 (§6)
- 四次测量危机的完整记录与提炼出的方法学 (§3；第四次为 v2.2 的合成基准捷径排查)
- 终端适应的真实边界：跨域冷启动成立、域内个性化否定、遗忘权衡与参数经济性重定性 (§7, v2.2)
- 终端效率三问的补完：能耗、CUDA Graph 终端口径、int4 混合精度配方与 W_res 机制发现 (§7.4, v2.2)
- 稀疏激活与冷启动兼容性验证 + CPU 端侧部署 + 安全框架 (§9, v4)

2. 架构与实现修正

2.1 PCN 架构

每层包含：自底向上提取 $u = W_{bu}(LN(x))$ ；自顶向下预测 $p = W_{td}(h_{above})$ ；预测误差 $e = clamp(u - p, \pm 10)$ ；**误差驱动的跨位置门控聚合**——压缩特征交互 $[e_i \odot e_j, e_i + e_j]$ 经 sigmoid 独立门（非 softmax 竞争）、因果掩码、Top-K 稀疏化后加权 $W_{lat}(e)$ ；状态更新 $h = GELU(W_{up}(LN(e + lat))) + W_{res}(x)$ （ W_{res} 恒等初始化）。

消融变体（贯穿全文）：

- **no_gating**：门控聚合换成因果 attention（误差流保留）——本文最强的「误差流」载体
- **two_pass**：真 top-down（pass 2 用更深一层状态做预测来源）
- 反馈消融、门控 softmax 化、门来源/值对象开关 (§5)

2.2 三轮实现修正（首次报告，附教训）

轮次	缺陷	症状	修复
R1	W_res 随机初始化（谱范数 ≈ 0.6 ） $\rightarrow$ 12 层梯度衰减 $316\times$ ；门控双重小尺度压缩 $\rightarrow g\approx 0.5$ 死锁；evaluate 未透传消融参数	PPL 卡 406 五千步不动	恒等初始化 + 门控 LayerNorm/Xavier + 参数透传

轮次	缺陷	症状	修复
R2	非因果泄露 (attention 未传 attn_mask、门控无掩码)——两个架构都能「看未来」	22M 模型 held-out WikiText top-1 准确率 99.6%	双侧因果化 (§3.1)
R3	基线超参次优 (lr=3e-4 对 Transformer 严重次优, 其最优为 1e-3)	假性 +56.8% 优势	对称 lr 扫描 (§3.2)

全部双向时代数据 (75 项) 作废归档; 本文所有数字均为因果修正后。

3. 测量方法学 (四次危机的提炼)

3.1 因果性是公理, 不是配置项

任何「预测下一 token」的跨位置交互必须显式因果化。**作弊探测器**: 训练后模型在 held-out 真实语料上 top-1 准确率 >50% 或 PPL 异常低 (<5), 几乎必然非因果——本研究的泄露正是由「PPL 2.24 好到不可能」暴露, 而非代码审查发现。

3.2 对照超参必须对称调优

统计稳定性 (多 seed、小方差) 不能补偿系统性偏差: 我们的假性优势有 5-seed、std 0.012 的完美统计形态, 仍然源于基线 lr 次优。任何架构对比必须双方各自完成同规模超参扫描后取各自最优。**架构最优超参本身是结果**: 本研究的 Transformer 最优 lr (1e-3) 与误差流变体 (5e-4) 相差 2-3 倍, 且互换代价巨大 (-83% 至发散)。

复发与勘误 (v2.2 补注): 该陷阱在 V6 收官系列复发——demo 与骨架系列全用了 lr 次优的 TF checkpoint (WT PPL 557 vs 公平版 215), 一度得出「TF 微调退化 -19.7%」的结论; 公平复测实为 +5.4% 改善。教训: **基线勘误不一定推翻结论** (ΔW 约束幅度在公平对下依然成立, $1.91\times$), 但必须先勘误再引用。

3.3 自建对照结构必须先用已知结论校准对照格

为分解实验在外部重写的「简化结构」= 未声明的多变量改动。本研究三次自建结构全部对照失效 (含已知对照格复现失败)。正确做法: 在原实现上加开关, 并先跑对照格校准。

3.4 同预算协议

一切对比固定 batch $\times$ seq $\times$ steps 的 token 总量与等效 batch; 单变量三臂消融 (full / 去 X / 换 X)。

3.5 合成基准的「高于随机」必须先过捷径天花板 (v2.2 新增)

自建合成任务上某臂准确率「高于随机」时, 必须先在**固定测试集上计算平凡启发式的得分天花板** (众数值/多数类/最近重复/unigram 等)——臂的得分 $\leq$ 天花板则信号被捷径解释。实例: MQAR 值有放回采样下「众数值」启发式天花板 0.1263 > 门控臂实测 0.115, 且后者得分随 n 的衰减模式与天花板一致 (§7.5); 改值唯一采样后臂精确回到随机。采样方式决定捷径的存在与否, **优先无放回/去捷径构造**。

4. 主结果: 规模-数据比规律

4.1 协议

TinyStories / WikiText-103 (GPT-2 tokenizer, 117.9M tokens 磁盘缓存) , seq 256, 41M tokens 固定预算 (5000 步 × 等效 batch 32) , 双方各自最优 lr 与 clip, 多 seed。模型 12 层, d ∈ {256, 384, 512} (21-63M 参数) 。

口径澄清 (响应 V3 审稿 Q2) : 所有规模点 (d256/384/512) 保持完全相同的 token 总量、步数与等效 batch; tokens/param = 训练 token 总量 ÷ n_params (含 embedding/LayerNorm 在内的全部参数 , 逐 run 记录于 results/<exp>/results.json 的 n_params 与 budget 字段) ; 每个 run 的最优超参映射同样逐 run 记录于该 JSON 的 config 字段 (lr/warmup/clip/wd) 。 WT d512 预测验证点: results/s512_*/ (各 seed 目录含完整 config 与 val 曲线) 。

4.2 规律曲线 (v2: 二维不对称, 11 数据点, bootstrap 95% CI)

减数据轴 (固定 d256, 数据量递减) ——优势单调上升, 无左端回落:

tokens	TF [95% CI]	NG [95% CI]	NG 优势	稳健性
2.5M	402.67	63.95	+84.1%	全胜
5M	268.63	42.93	+84.0%	全胜
10M	128.82	28.27	+78.1%	全胜
20M	32.88	19.92	+39.4%	全胜
41M	15.18 [14.66,15.86]	16.50 [16.45,16.55]	-8.8%	负

加参数轴 (固定 41M tokens) ——倒 U:

tokens/param	TS	WT	稳健性
~7500	—	-64.9%	负
~1900	-8.8%	+20.7% (TF [210,238] / NG [175.6,176.4])	全胜
~1025	+43.3%	+59.2% (n=5; TF [290,447] / NG [128,168])	全胜
~650	+35.5%	+48.5% (n=5; 全胜)	全胜

逐点 CI 与 run 清单: analysis_v2/scale_curve_with_ci.json。 **「全胜」= NG 最差 seed 优于 TF 最好 seed**——所有正优势点均达此标准 (强于 CI 不重叠) 。

结论 (范围限定表述, 响应审稿 W1) : 在本研究参数范围 (21-63M) 、token 预算 (≤164M) 与两个域内: **误差流优势随数据稀缺单调增大 (至 +84%) ; 随参数加大先增后减 (峰值 ≈1025 tokens/param)** 。「减数据比加参数更能放大优势」直接指导终端个性化部署 (冻结中等模型 + 少量用户数据) 。 >1B 参数与 >164M tokens 未测。

附带发现 (稳定性) : NG 的 seed 标准差在两个低数据点上比 TF 小 1-2 个数量级 (WT d256: 0.53 vs 17.90; WT d512: 2.39 vs 65.66) ——**误差流不仅更准, 训练还显著更稳定**, 这对端侧部署 (不可挑选 seed) 是独立于 PPL 的实际优势。

域难度主轴: 同比 1025 tokens/param, 难域 (WT) 优势高于简单域 (TS) 约 17 个点; v1 的「倒 U」表述在数据量轴上不成立 (见上表: 单调) , 仅在参数轴成立——v2 已按二维不对称规律改写。

外推验证: WT d512 数据点在曲线其余部分确定后预测 (预测带 [+30%, +55%]) , 实测 +37.7% 落在带内——规律的第一次成功预测。

充分训练翻转：WT d256 @164M tokens (20K 步) 下 Transformer 53.1 vs no_gating 87.5——数据充裕后 TF 渐近优势接管。误差流的优势严格属于低数据/参数比区间。

4.3R 超参敏感性对照 (v2, 响应审稿 W2/W4)

warmup	TF (lr 1e-3)	NG (lr 5e-4)
100	14.98	14.85
500 (基线)	15.14	14.13
1500	13.55	14.01

发现：warmup 对 TF 敏感 (500→1500 改善 10.5%)、对 NG 不敏感 (±1%)。两边各自最优时收敛区 (TS d256) 差距为 TF 领先 3.4% (此前单一 warmup 下的 8.7% 含超参不对称成分)。关键定量论证：warmup 敏感性的量级 (~10%) 远小于低数据区优势 (+59%~+84%)，规律的主结论不受此混杂威胁。

4.4 第三架构对照 (09-10 补充; v2.2 升级 n=5/域, 响应 V3 审稿 W2/W3)

以可学习因果衰减注意力 (softmax(QK⊞+λ(t-i)), RetNet/GLA 线性注意力家族的最小代理; Mamba/RWKV 在 Windows 不可编译, 纯 torch 复刻的数值风险大于代理价值) 作为第三族 (lr 1e-3, 另有 3e-4 两点对照; n=5 seed/域, decay_{ts,wt}_lr1e3_s0-4) :

域	decay 最优	Transformer	no_gating
TinyStories	15.83±0.67	15.18±0.80	16.50±0.07
WikiText-103 (低数据区)	219.4±24.6	221.97±17.90	175.96±0.53

decay 均值略优于 TF (WT 上 +1.2%, CI 重叠) 但远不具备误差流的低数据区优势 (NG 对 decay 领先 19.8%) ——误差流的 +20.7% 不是「替换 softmax」或「添加衰减先验」类单子件改动可以获得的, 与 §5 的组合性质结论形成跨实验呼应。

4.5 定位含义

终端场景 (用户数据有限 × 相对大参数) 恰好落在峰值区——该规律为「什么区间用什么架构」提供了可操作的决策依据。诚实边界: 43-61% 是改进幅度而非数量级跃迁; 规律在 <650 与 >1B 参数两个方向均未测。v2.2 修正: 该区间的增益可兑现场景是跨域/冷启动适应 (§7.3) ——域内已收敛模型的个性化微调无适应空间 (§7.2), 部署建议按 §8.1 的双准则执行。

5. 机制分析：组合性质与对称不可达性

5.1 现象

小样本精确复制任务 (H 个随机 token + 分隔符 + 复制, 1000 步预算, 12L-64d) : 因果 PCN 5/5 seed 学会 (copy loss 0.17-0.32), 同规模因果 Transformer 0/30 (恒 unigram 3.43; 因果版三长度 ×5 seed 0/15 + lr 调优复检 0/15) 。

5.2 十三变体双向对照 (3-seed each)

已排除的必要条件假说 (加法线失败 + 反向线存活 = 双向排除) :

假说	标准块+子件	PCN-子件
门来源 (feat 交互 vs q-k 相似度)	—	qk 门在 PCN 内 0.047-0.092 ⊠
值对象 (误差 e vs 输入 h)	—	wlat_h 0.022 ⊠ (比 e 更好)

假说	标准块+子件	PCN-子件
误差残差性 (e=u-p)	—	e=u (no_feedback) 0.277 □
FFN 干扰	去 FFN 3.437 □	+FFN 0.074 □
更新通路形态	S2/S3 3.435 □	原生 □
门对比度 (头平均)	单头门 3.435 □	原生 □
自信息直注增量	S5 3.435 □	—
独立 sigmoid (vs softmax 竞争)	—	softmax 化 1.109 (3/5 不稳定) □□

softmax 竞争化是唯一使 PCN 退化的单改动（不稳定而非完全失败）——独立门是该列表中**唯一存留的单子件必要条件**，但仅有它不够（tf_sigmoid 有独立门仍失败）。

实现澄清（响应 V3 审稿 Q3）：移植 = 在标准块结构中**直接添加对应模块并随机初始化**，随后与对照完全相同的从零训练协议（复制任务无预训练阶段，不涉及预训练权重移植或微调）；拆除 = 原实现上以开关参数旁路该子件（教训 9：不在外部重写结构）。渐进插值、初始化统计匹配、蒸馏式迁移等更强的移植策略**未测试**，列入中期实验清单（附录 D）。

5.2R 全因子补格 (v2, 响应审稿 W3: 交互效应检验)

2×2×2 全因子矩阵（门来源 × 值对象 × FFN，各 3 seed，factorial_fill.json）：

	e 值	h 值
feat 门 -FFN	0.21 □	0.022 □
feat 门 +FFN	0.31 □	0.27 □
qk 门 -FFN	0.09 □	0.047 □
qk 门 +FFN	0.14 □	0.074 □

八格全部成功——PCN 骨架内不存在能破坏复制能力的子件组合；主效应与交互效应均为「无害」。结合标准块侧五连败 (§5.2)，组合性质结论从「检验过的变体集」升级为**完整因子空间内确认**。

5.3 结论：组合性质

复制能力的必要条件是 **PCN 骨架多个子件的组合**——提取-误差-融合-恒等残差的耦合结构，不可分解为单一组件。

5.4 对称不可达性

- 性能层 (V1-V3, 20+ 实验)：从 Transformer 修补出发 → 退回 Transformer
- 机制层 (本研究)：从标准块移植子件（五种）→ 救不回复制能力；从 PCN 拆除已测子件 → 能力保持 □ **在我们检验的变体集、训练预算（1000 步）与移植策略下，该能力未能通过子件移植复现，也未能通过拆除子件消除。** 我们无法断言此结论在更大规模、更多干预方式（如渐进式移植、初始化匹配、辅助损失训练等）下仍然成立——但这组双向证据支持「换基线而非打补丁」的架构研究策略。

5.5 行为签名 (补充)

跨模型 CKA：纯 PCN (two_pass) 0.112 / 混合版 0.469——表示结构差异显著。误差范数与 token 惊讶度的相关四次测量 ≈ 0 (0.10/0.05/0.015/-0.06)：「误差编码惊讶」的经典预测编码假说在本设置下**未获支持**。

6. 负结果：局部学习规则的适用边界

级别	设置	结果
0	两层 MLP + K 步迭代推断	完全等价 (0.0002 vs 0.0002; K=1 输出层梯度 $\cos = 0.9995$)
1	PCN 的 W_{td} (玩具任务)	零敏感度 (冻结/局部/全 BP 的 loss 全同——任务不依赖反馈)
2	PCN 主路径 (LM)	2.4-3.7× 差距 ($m1 = 39.8-49.6$ vs 基线 13.6-16.6)

级别 2 的两个混杂因素已对称排除：局部 lr 四点扫描（全平台 2.4-2.6×）； $K \in \{2,3\}$ 迭代推断矩阵（数值稳定但性能更差，且 K-pass 纯 BP 对照 13.60 证明推断本身无代价）。

结论（限定范围表述）：在本研究的 W&B 实现变体、更新方案 ($K \in \{1,2,3\}$) 与优化设置下，等价性在「MLP+推断收敛」与「PCN 结构」之间存在 2.4-3.7× 的性能差距。我们**不能**由此推广到所有生物合理的局部学习规则——其他变体（如松弛权重对称性、不同阻尼、更大 K 值、反馈对齐等）可能在 PCN 上表现不同。「以局部规则实现终端在线学习」的路径需要探索非 W&B 形式或等待新理论。

实现澄清（响应 V3 审稿 Q4）：本实现的权重对称性内建于架构——局部规则复用前向的 W_{td} 本体 ($p = W_{td}(h_{above})$)，无独立反馈矩阵；K-pass 的逐层更新顺序、lr_loc 与阻尼等全部超参逐 run 记录于 local_rule_level* 系列 JSON 的 config 字段。反馈对齐（随机反馈矩阵）、 $K > 3$ 、阻尼调度等变体矩阵**未测试**；V6 已按预案关闭该线 (V6_CLOSURE.md)，变体筛选列入中期清单（附录 D）。能耗口径：BP 训练/推理的 J/token 已有测量 (\$7.4 T4)，逐局部规则变体的 wall-clock/能耗对比随该线关闭不再补充。

附带发现：grad_clip 0.5 对 no_gating 更优 (16.56→14.13)；所谓 K-pass 增益 (13.84) 实为 clip 混杂（差 2% 在噪声内）。V6 按失败出口关闭，替代路径（样本效率微调的终端适应）见 §7；终局文档 results/V6_CLOSURE.md。

7. V6 收官：权重约束、遗忘与终端适应 (v2.2 新增)

本章全部实验使用**公平 checkpoint 对** (PCN ts/wt_causal_no_gating_s{1-4}，最优 lr 3e-4；TF ts_tf_lr1e3_s{1-4} / wt_tf_lr1e3_s{1-4}，最优 lr 1e-3——与 §4 fairness 同源)。

微调协议（除非另注）：冻结 embedding + 前 6 层，AdamW，clip 1.0，6 个 256-token 训练块。

7.1 权重约束 = 第二涌现性质（幅度稳健，含义重定性）

现象：微调时 PCN 的可训练层权重变化幅度始终约为 TF 的 1/2 (E1：后半层 ΔW 0.85-1.17 vs TF 1.65-2.00)。

双向排除（协议同 §5：PCN 侧去子件应增大 ΔW 、TF 侧加子件应减小 ΔW ）：误差减法 (E3，泛化 72.9% vs 74.7% 仍持平)、GELU 门控 (0.86×/1.06×)、norm_update LN (0.97×)、 W_{res} 恒等残差 (0.93×/0.94×) ——四个单子件假说全部排除。

公平基线复核：原始测量用的 TF checkpoint 为 lr 次优 (WT PPL 557 vs 公平版 215)；换公平对复测 TF/PCN $\Delta W = 1.91\times$ (公平) vs $1.88\times$ (次优) ——幅度结论对基线质量稳健。

含义重定性（由 7.2 的遗忘数据强制）： ΔW 小不等于功能稳定。权重约束应表述为「**参数经济性/高函数敏感度**」——单位参数变化带来更大的函数移动（适应快、遗忘也快）——而非「抗遗忘保护」。

7.2 灾难性遗忘基准 (GOAL V6#2 首次执行)

双臂 A→B→A 交替任务流（域内主题切换：TS 奇幻池↔校园池；跨域远征：TS↔WT），双口径，4 seed。

域内校准网格 (lr×steps, 24 格 × 双架构) 无一为正——即使最温和设置 (lr 5e-5 × 60 步) 也让 held-out 恶化 (PCN -7.4% / TF -4.0%)，随强度单调恶化。**结论：22M/40M-token 收敛模型在 1.5K token 同域数据上没有可挖的适应空间；任何「个性化微调」优势必须来自域差闭合**（见 7.3）。

匹配适应水平的跨域比较 (calibrated 口径, 各自最优超参)：适应增益匹配 (held_WT PCN +89.0% vs TF +85.1%) 时，PCN 的家域遗忘**更多** (TS 通用 PPL +31.9% vs TF +16.7%，0/4 seed 占优) ——与「权重约束→低遗忘」的预测相反，构成 7.1 重定性的直接证据。

激进域内重复微调 (aggressive 口径)：PCN 抗损能力显著更强 (forget +43.3% vs TF +90.8%，3/4 seed；通用漂移 5.1× vs 9.0×) ——高可塑性架构的另一面。

规模边界：以上均为 22M、300 步内、1.5K-token 任务的快速范式 (4 seed)，不外推到长程在线学习。

7.3 跨域冷启动适应：单发与流式

单发 (1.5K token 用户数据，300 步冻结微调，WT base → TS 用户，5 用户)：PCN 平均 PPL 改善 +**58.5%** vs 公平 TF +**5.4%** (PCN 5/5 全胜，且起点 PPL 更差 2392 vs 2257；适应耗时 4.6s)。（内部报告曾记录 TF 为 -19.7% 恶化——该数字基于次优 TF checkpoint，公平复测后修正为小幅改善；教训 8 的复发实例，见 §3.2。）

流式 (prequential: 8 批 × 256 token 逐批到达，每批先评在线分再适应 60 步，一次性通过)：

	PCN	TF
在线增益 (vs 冻结基线)	+24.0%	-80.9%
流末用户 held-out	+27.8%	-183.8%
累积 ΔW	0.599	1.120 (1.87×)

TF 对每个 256-token 小批灾难性过拟合 (末批在线 PPL 12470)；域内对照流两架构双输 (-189%/-209%)。**部署准则：跨域/冷启动场景用误差流架构边用边学；域内已收敛模型应冻结。**

7.4 终端效率三问补完 (T4-T6)

能耗 (T4, 首次测量)：训练/服务端口径 PCN 门控 bmm 每 token 能耗最低 (训练 1.148 vs TF 1.253 mJ; b32 推理 0.618 vs 0.709)；裸 eager 的 b1 终端口径曾为 TF 的 2 倍。

CUDA Graph (T5)：整前向捕获重放 (静态形状) 后，b1 终端口径吞吐 36.7K→197K tok/s (×5.4)，达 TF-graph 的 **102.2%** (no_gating 91.5%)，能耗反转为 **0.51 vs 0.71 mJ/tok (-28%)**；数值位级等价 (|Δlogit|=0 全配置)。「低功耗终端」论点在 **graph 部署口径下成立**。（边界：自回归逐 token 生成需按长度预捕图；无 graph 的 eager 口径 PCN 仍慢于 TF。）

int4 量化 (T6)：TF 全配置近无损 (g64 +0.1~0.6%)；PCN 的 RTN 敏感性**全部来自 W_res**——仅量化 W_res (占参数 0.4%) 单独造成 +4.2~4.5% 损失，将其除外后 int4-g64 近无损 (+0.2~0.4%)。机制：PCN 残差主干穿过 W_res matmul (**非加性残差**)，量化误差直接进入主干并跨层复合；TF 的加性残差天然隔离误差。这与 V4 的 W_res 恒等初始化 (梯度直通) 是**同一设计选择的两面**。端侧配方：int4-g64 非对称 + W_res/embedding 保 fp16 (32.0 MB @22M；22M 档 embedding 占 61% 参数，int4 收益在 0.5B+ 档才充分兑现)。GPTQ 无需立项。

7.5 MQAR 否定性结果 (防过度主张红线)

标准 Multi-Query Associative Recall (键值绑定) 四阶段测试 (4 臂 $\times n \in \{16, 32, 48\}$, 预算至 8000 步 $\times b64 = 8\times$ 基准, D64-128) : **TF / 衰减注意力代理 / no_gating / PCN 门控全部随机水平**。阶段一至三中门控臂 $n=16$ 的 0.115 (7 $\times$ 随机) 经混淆排查确认为**采样捷径伪影**——值有放回时「众数值」启发式在同一测试集天花板 $0.1263 > 0.115$; 值唯一 (无捷径) 复测中门控臂精确回到随机。

结论: \$5 的复制任务优势不可外推到键值绑定; 本文的召回主张锚定复制任务。键值绑定的解出需要远超玩具尺度的容量 (与 Zoology/Based 的 d256+ 设置一致), 留待规模扩展期。此混淆已提炼为方法学教训 (先算捷径天花板, 再解读「高于随机」)。

9. V7 终端形态: 稀疏兼容性 + 端侧部署 + 安全框架 (v4 新增)

9.1 稀疏激活与冷启动兼容性 (第五次测量偏差修正)

初始结论 (后修正) : 25% Top-K 稀疏激活「摧毁冷启动能力」 (+64% $\rightarrow$ -257%)。

混杂来源: 稠密 PCN 使用 WikiText checkpoint (跨域冷启动 = 强项), 稀疏 PCN 使用 TinyStories checkpoint (域内微调 = 已知无优势) ——域效应被误判为稀疏效应。

四臂对照修正:

臂	预训练域	微调域	冷启动改善
稠密 $\times$ WT	WikiText	TS	+53.2%
稀疏 25% $\times$ WT	WikiText	TS	+57.9%
稠密 $\times$ TS	TinyStories	TS	-317.2%
稀疏 25% $\times$ TS	TinyStories	TS	-268.6%

修正后结论: 稀疏激活与冷启动**完全兼容**。终端部署推荐更新为「**稀疏 PCN 全能**」。

9.2 CPU 端侧部署

指标	结果	终端判据
batch1 推理吞吐	8,603 tok/s	$\geq 50 \square$
自回归生成	112.9 tok/s (8.9 ms/token)	实时 $\square$
冷启动适应	+55.0% PPL / 22.7 秒	≤ 30 秒 $\square$
模型大小	80 MB (21M 参数)	终端可装 $\square$
数据不出端	全流程本地	$\square$

9.3 安全框架

层	机制	防护目标
输入过滤	长度/重复/字符集/注入检测	投毒适应
速率限制	频率 + 总步数双控	过度适应退化
审计回滚	checkpoint 快照 + 一键回滚	适应不可逆
所有者绑定	PBKDF2 身份 + 权重加密	模型被盗

9.4 稀疏度扫描

act_sparse	PPL	变化
0%	16.50	—
25%	14.13	-14.4% (最优)
50%	14.14	饱和

8. 讨论与局限

8.1 对终端智能愿景的含义

倒 U 规律的峰值区与终端场景重合，且 v2.2 的适应实验把「重合」细化为**可操作准则**：跨域/冷启动（新用户、换域、预训练-部署域差）用误差流架构做边用边学（流式 +24% vs TF -81%）；域内已收敛的模型应冻结（域内流式双输）。在线学习方面，W&B 局部规则已证伪 (§6)，替代路径是「BP 微调的样本效率 + 权重约束的参数经济性」。效率侧，graph 部署口径下终端吞吐/能耗短板已清偿 (§7.4) ——但 43-61% 的幅度、+24% 的流式增益不足以单独支撑终端愿景，稀疏化与系统工程的叠加仍是必需。

8.2 局限（诚实清单）

1. 规模上限 63M 参数 / 单卡——规律在 >1B 与 <650 两端未测
2. 第三架构以衰减注意力为代理（RetNet/GLA 家族精神），完整 Mamba/RWKV 未测；代理与 TF 重合暗示衰减核家族可能同样不具备该优势，但需正式实现确认
3. 复制任务是合成任务；「1000 步内学不会」≠「永远学不会」——结论限于小样本预算；且复制优势**不可外推到键值绑定**（MQAR 四臂全随机，§7.5）
4. 倒 U 的机理（为何低数据区占优）只有现象学刻画，无理论模型
5. ~~效率限制~~：v2.1 的 bmm 重构（训练 96% TF、b32 反超 +14%、int8 无损）之上，v2.2 补齐能耗（服务端最优）、CUDA Graph 终端口径（b1 102%/能耗 -28%）、int4 混合精度配方（W_res 例外，近无损）——效率三问在 graph 部署口径下全部解除；残余边界：自回归生成的按长度预捕图、eager 口径仍慢、22M 档 int4 收益受 embedding 占比压制
6. §7 的适应/遗忘/流式结论均为 22M、≤300 步、1.5K-token 快速范式（≤4 seed）——不外推到长程在线学习与更大规模；域内「无适应空间」的边界亦随规模可能移动
7. 遗忘的权衡：匹配适应下 PCN 遗忘更多（高可塑性端）——终端多用户/多域共存的场景需要恢复机制 (§7.2 的再学习臂) 或参数隔离，未在本研究范围内

8.2R 规模扩展计划（响应审稿 W1）

阶段	目标	预计时间
短期（8 周内）	一个 200-300M 参数点在 WikiText-103 上的验证	获取多卡资源后启动
中期（6 个月）	200M + 500M 两档完整 tokens/param 曲线	视资源情况
长期	>1B 参数验证	需集群级算力

操作建议的条件限定：终端个性化部署建议仅在 tokens/param ∈ [~650, ~1100] 且参数 ≤1e8 的区间内直接适用；超出此范围需先验证。

8.3 方法学立场

本研究四次测量危机（非因果泄露、基线超参次优——含 V6 系列复发并勘误、自建对照失效、合成基准频率捷径）全部被**预设的验证程序**（而非运气）捕获——其中第四次（\$7.5）是「高于随机 ≠ 学会任务」的直接示范。我们主张：架构比较论文应报告其验证程序（因果探测器、超参对称性、对照校准、捷径天花板）与结果本身同等重要的地位——尤其在单点「惊人优势」出现时，**先怀疑测量，再相信架构**。

附录 A：关键数字索引

开源仓库： <https://github.com/Asaluther/PRISM-V4> — 全部代码、run 脚本、结果 JSON 可复现
V7 数据： results/v7/ (a2_scan / a4_fixed / b2_cpu / b3_coldstart / c_security)

数据	文件
规律曲线 7 点	results/analysis_v2/scale_data_ratio_curve.json
因果 5-seed（两域）	results/analysis_v2/{ts,wt}_causal_seed_validation.json
公平判定 + d384/d512	results/analysis_v2/fairness_final.json, d384_confirm.json
机制 13 变体	results/mechanism/{copy_mechanism_s*.json, gate_source_v2.json, block_ablation.json}
局部规则三级别	results/mechanism/{local_rule_test 系, local_rule_level*_*.json}
行为签名	results/analysis_v2/signatures_causal_*.json
骨架约束（第二涌现性质）	results/mechanism/{skeleton_constraint, skeleton_s3s4, skeleton_fair_recheck}.json
遗忘基准（双口径）	results/mechanism/forgetting_benchmark_{calibrated, aggressive}.json + forgetting_calibration.json
跨域适应（单发/流式）	results/demo/{personalization_demo, streaming_demo}.json
终端效率 T4-T6	results/efficiency/{t4_energy, t5_b1_graph, t6_int4}.json
MQAR 四阶段（否定性）	results/mechanism/mqar_{benchmark,phase2,phase3, phase4}.json
双向时代作废归档	results/_invalid_bidirectional/（README 含报警现场）

附录 B：实验统计

仓库共 205 个 run 级结果文件（results/**/results.json）：其中 75 项为双向时代作废归档（results/_invalid_bidirectional/），有效因果时代训练 run ≈130；v2.2 另含 V6 收官系列 ≈40 个短程适应/机制/效率实验（多数为 60-300 步微调与玩具任务）。GPU 总时长 ≈45 小时；全部实验可由 run_*.sh 与本报告所引脚本幂等复现。（v2.2 统一了 v2.1 中 130/~140 的口径矛盾——响应 V3 审稿附加项。）

PRISM V4-V6 · 2026-09-07 至 09-11 · 单卡架构研究完整记录

附录 C：术语表（响应审稿 W5）

缩写	全称/定义
PCN	预测编码网络 (Predictive Coding Network) , 本研究的非 Transformer 骨架
NG / no_gating	PCN 的误差流变体: 门控聚合替换为因果 attention, 误差流保留——最强配置
TF	Transformer 对照基线 (Pre-LN + SDPA 因果注意力)
误差流	$e = u - p$ (自底向上提取减自顶向下预测) , 逐层计算的残差信号
门控通路	PCN 的跨位置聚合机制: 压缩特征交互 $\rightarrow$ sigmoid 独立门 $\rightarrow$ Top-K $\rightarrow$ 加权 W_{lat} 值
对称不可达性	从标准块移植子件无法获得、从 PCN 拆除子件不损失某能力的双向实验性质
tokens/param	训练 token 总量 $\div$ 参数量 (数据-参数比)
全胜	NG 的最差 seed 优于 TF 的最好 seed (强于 95% CI 不重叠的稳健性声明)
W&B 局部规则	Whittington–Bogacz 式预测编码局部学习规则 (无需全局反向传播)
K-pass	迭代推断: K 遍前向中逐层松弛误差 (W&B 等价性的推断条件)
权重约束	PCN 微调时 $\Delta W \approx TF/2$ 的幅度约束 (第二涌现性质; 含义=参数经济性, §7.1)
公平 checkpoint	各架构在其最优 lr 下训练的对照模型 (TF $1e-3$ / NG $3e-4$, §4 协议)
prequential	先预测后适应的在线评估协议: 对未见过批次的预测质量即在线得分 (§7.3)
MQAR	Multi-Query Associative Recall: 键值绑定标准合成基准 (§7.5, 否定性)

附录 D: 审稿意见回应索引

D.1 V2 审稿 (v2.1 时点)

审稿弱点	响应	所在节
W1 规模/外推	措辞限定 + 二维规律改写 + 峰值点 $n=5$	§4.2
W2 基线/超参对称	warmup 敏感对照 + decay $n=3$ + 定量论证	§4.3R/§4.4
W3 因子设计	$2 \times 2 \times 2$ 全因子 8 格补齐 (全部成功)	§5.2R
W4 统计细节	bootstrap CI + 「全胜」稳健性声明	§4.2
W5 可复现性	术语表 (本附录 C) ; 开源仓库计划: GitHub + smoke test + 相对路径 (下版)	附录 C/D

审稿弱点	响应	所在节
效率局限#5	bmm 重构 6.12× (达 TF 96%) + 推理 batch32 反超 +14% (v2.1) ; v2.2 补能耗/CUDA Graph b1 102%/能耗 -28%/int4 配方——三问解除 (§7.4)	§7.4
(v2.2 新增) V6 终端主张	单发/流式跨域适应 + 遗忘边界 + MQAR 否定性 (防过度主张)	§7
(v2.2 新增) 测量纪律第 4 条	合成基准捷径天花板 (MQAR 混淆排查)	§3.5

D.2 V3 审稿 (v2.2 时点, 针对 v2.1 文本; 总体 7.5/10, Soundness 6/10)

V3 弱点/建议	v2.2 响应	状态
W1 规模外推不足; 建议 200-300M 或外推不确定度量化	维持资源决策 (规模扩展搁置, 8.2R 计划在); §4.5/§8.1 的部署建议已收紧为双准则并显式限定已测区间	部分解决 (措辞) + 挂账 (实验)
W2 基线不全/未对称调优; decay 单 seed	decay 升级为 n=5/域 (lr1e-3, 另有两点 lr 证据 3e-4 vs 1e-3) ; Mamba/RWKV 完整实现仍以衰减代理代替 (编译限制已说明) ; optimizer/wd/init 对称网格未做——挂账	部分解决 (decay 补种) + 挂账
W3 seed 数不统一、[全胜] 判定、run 元数据	「全胜」保留为 补充性 稳健声明 (正文标注其定义) ; decay 补至 n=5; 全局 seed 统一 (≥7) 与分布检验/smoke test/run_metadata.csv 列入仓库路线图	部分解决+挂账
W4 不可达性外推过强	§5.4 的限定表述维持并加强 (§5.2 实现澄清: 直接替换+随机初始化+从零训练, 渐进/蒸馏未测) ; 渐进插值与蒸馏列入中期实验清单	措辞解决+挂账 (实验)
W5 局部规则变体空间未覆盖	§6 范围限定维持; V6 已按预案关闭该线 (决策记录) ; K>3/反馈对齐/阻尼变体筛选与逐变体能耗列入中期清单; BP 口径能耗已有 (T4)	挂账 (明确)
附加: run 数 130 vs ~140 矛盾	附录 B 统一口径 (205 文件 = 75 作废 + ~130 有效 + 机制/效率; 另有 V6 ~40)	已解决
长期项: 能耗 / batch1 kernel 优化	T4 能耗首次测量 + T5 CUDA Graph (b1 102%、能耗 -28%) + T6 int4 配方——审稿「长期优先级」两项已在 v2.2 完成	已解决
Q1 超参映射	逐 run 记录于 results/⟨exp⟩/results.json 的 config 字段 (§4.1 澄清)	已答
Q2 协议等效性/tokens-param 口径 /d512 run 路径	§4.1 口径澄清; results/s512_*/	已答
Q3 移植实现细节	§5.2 实现澄清 (直接替换+随机初始化+从零训练; 渐进/初始化匹配/蒸馏未测)	已答

V3 弱点/建议	v2.2 响应	状态
Q4 W&B 实现细节	\$6 实现澄清 (对称性内建于 W_td 复用; 超参见 local_rule_level* JSON)	已答
Q5 最小可行 200-300M 方案	8.2R 短期行 + 最小配置建议: d1024/24L ($\approx 350M$) 单点 $\times 3$ seed $\times 20K$ 步 $\approx$ 单卡 A100/H100 约 60 GPU·h 或 4080 约不可行 (需租用) ——资源到位后启动	已答 (计划)

V3 建议中已列入中期清单的实验 (资源/优先级裁决后执行) : 渐进插值移植、蒸馏式迁移、复制任务延长预算 (5K-20K 步)、局部规则变体筛选矩阵 ($K \leq 10$ 、反馈对齐、阻尼调度, d128 玩具规模预筛)、optimizer/wd/init 对称网格、全局 seed ≥ 7 统一与分布检验改造。